PROYECTO GEN-MAMA-MX

Explicación del Proyecto

Pipeline de Medicina Genómica de Precisión para Cáncer de Mama en Poblaciones Latinas

TCGA-BRCA → Secuenciación NGS → AlphaFold 3 → Docking Molecular → Fármacos

Tipo de documento	Explicación técnica y científica del proyecto
Audiencia objetivo	Google.org, inversionistas, aliados institucionales, clínicos
Dataset base	TCGA-BRCA — 1,084 pacientes, acceso abierto (cBioPortal)
Herramienta central	AlphaFold 3 (Google DeepMind) + Boltz-1 (MIT)
Docking	AutoDock Vina 1.2 + DiffDock (deep learning)
Estado del arte en MX	Consenso Mexicano 2025 ya incluye alpelisib y capivasertib
Organización líder	Universidad de Sonora (UNISON) + IMSS/ISSSTE Hermosillo
Convocatoria objetivo	Google.org Impact Challenge: AI for Science 2026

1. ¿Qué es GEN-MAMA-MX?

GEN-MAMA-MX es un pipeline computacional de medicina genómica de precisión diseñado específicamente para cáncer de mama en poblaciones mexicanas. El objetivo central es identificar qué proteínas cambian de forma por el tumor en cada paciente y qué fármacos ya existentes pueden bloquearlas.

La premisa del proyecto es directa: el fármaco existe. El Consenso Mexicano 2025 ya incluye alpelisib y capivasertib como tratamiento estándar para mutaciones específicas. Lo que no existe es el puente diagnóstico que conecta la mutación del tumor con el fármaco correcto para cada paciente — especialmente en el sector público, donde menos del 3% de las pacientes acceden a diagnóstico molecular.

> Si esto funciona para un perro con $2,000 dólares y una IA, ¿por qué no lo estamos haciendo para las 30,000 mujeres mexicanas diagnosticadas con cáncer de mama cada año?

2. El Pipeline: de la Biopsia al Fármaco

El pipeline de GEN-MAMA-MX está compuesto por 10 pasos organizados en cuatro fases. Cada paso transforma la información en algo más accionable que el anterior.

Fase	Paso	Nombre	Qué ocurre

Entrada clínica	1	Biopsia dual	Se toman dos muestras del mismo paciente: tejido normal (referencia) y tejido tumoral. Tener ambas del mismo individuo es crítico: las diferencias genéticas que se encuentren son causadas por el cáncer, no por variaciones naturales entre personas.
Entrada clínica	2	Extracción de ADN	Del tejido se extrae el ADN genómico. En el prototipo se usan datos públicos ya secuenciados (TCGA-BRCA) con exactamente esto: el perfil genético de tumor y tejido sano de ~1,000 pacientes.
Análisis genómico	3	Secuenciación NGS	Se secuencia el ADN de ambas muestras con tecnología de nueva generación (Illumina). Produce millones de lecturas del código genético que se alinean contra el genoma humano de referencia.
Análisis genómico	4	Variantes somáticas	Se compara la secuencia del tumor contra tejido sano. Cada diferencia que aparece solo en el tumor (no en tejido normal) es una variante somática: la mutación que el tumor adquirió y que lo hace crecer descontroladamente.
Análisis genómico	5	Anotación funcional	Se anota cada variante para saber en qué gen ocurrió, si cambia la proteína que produce, y si está clasificada como patogénica en ClinVar u OncoKB. Se priorizan las variantes missense en genes oncogénicos.
IA estructural	6	AlphaFold 3 (WT)	AlphaFold modela la estructura 3D de la proteína en su forma normal (wild-type). Genera el archivo .pdb con la geometría exacta. El score pLDDT indica confianza de la predicción.
IA estructural	7	Boltz-1 (Mutada)	Boltz-1 (MIT, sin límite de jobs diarios) modela la misma proteína con la mutación tumoral. El RMSD mide cuánto cambió la forma: mayor RMSD = mayor cambio conformacional = mayor oportunidad terapéutica.
IA estructural	8	Binding pockets	fpocket identifica las cavidades 3D donde un fármaco puede encajar físicamente. Calcula las coordenadas exactas (caja de docking) para el siguiente paso.
Fármacos	9	Docking molecular	AutoDock Vina prueba 50+ fármacos conocidos (ChEMBL, DrugBank) contra cada bolsillo de unión. El score en kcal/mol indica afinidad: más negativo = mayor unión al fármaco.
Fármacos	10	Fármacos repositionables	Si un fármaco se une mejor a la proteína mutada vs. WT (Δscore ≤ −1.0 kcal/mol), es un candidato repositionable: podría ser específico para el tumor y ya está aprobado para otro uso.

3. Variante Somática vs. Variante Germinal

Esta es una de las distinciones más fundamentales del proyecto. La razón por la que GEN-MAMA-MX necesita ambas muestras (tejido sano y tejido tumoral) del mismo paciente es precisamente para separar estos dos tipos de variante.

3.1 Variante Germinal — Naciste con ella

- Ocurre en el óvulo o espermatozoide antes de que nazca la persona. Desde el primer momento, TODAS las células del cuerpo la tienen.
- Se hereda — sus hijos tienen 50% de probabilidad de heredarla.
- Aparece igual en tejido sano y en tumor al secuenciar ambos.
- Relevancia clínica: predisposición, prevención y consejo genético familiar.
- Ejemplos clásicos en cáncer de mama: BRCA1, BRCA2, PALB2.

3.2 Variante Somática — El tumor la adquirió

- Ocurre durante la vida de la persona, en una célula concreta que empieza a dividirse de forma descontrolada. Solo ese linaje celular la tiene.
- No se hereda — no existió en las células reproductoras.
- Aparece SOLO en el tumor, ausente en tejido sano — esta diferencia es exactamente lo que busca el pipeline.
- Relevancia clínica: blanco terapéutico directo para ese tumor específico.
- Ejemplos: PIK3CA H1047R (29.5% de tumores de mama), TP53 R175H, ERBB2 amplificación.

> Por qué GEN-MAMA-MX necesita ambas muestras: al comparar tumor vs. tejido sano del mismo paciente, las variantes germinales se cancelan automáticamente (aparecen en los dos) y el pipeline se queda solo con las somáticas, que son el blanco terapéutico real.

Nota ética importante: si durante el análisis se detecta accidentalmente una variante germinal como BRCA1 o BRCA2, eso tiene consecuencias para la familia de la paciente. El protocolo de consentimiento informado del proyecto contempla qué se hace con esos hallazgos incidentales y con qué acompañamiento de consejo genético.

4. Secuenciación NGS: Cómo se Convierte el Tejido en Datos

El paso 3 del pipeline — la secuenciación de nueva generación (NGS) — es el que convierte el tejido biológico en datos digitales que puede procesar una computadora. Hay tres plataformas dominantes en 2025:

Plataforma	Lecturas	Precisión	Costo/exoma	Uso principal

Illumina NovaSeq X	75–300 bp (short-read)	Q40 · 99.99% / base	~$300 USD	Estándar clínico oncológico
PacBio HiFi (Revio)	15–25 kb (long-read)	>99.9% / lectura	~$800 USD	Variantes estructurales complejas
Oxford Nanopore (ONT)	>100 kb (ultra-long)	~99% Q20+	$1K–300K equipo	Tiempo real, portátil, epigenómica

Principio físico de cada plataforma

Illumina usa síntesis con flash: fragmenta el ADN en trozos de 150–300 pares de bases, los amplifica en millones de colonias idénticas, y una cámara fotográfica captura el color de cada base fluorescente añadida ciclo por ciclo. Alta precisión, lecturas cortas, procesamiento masivamente paralelo.

PacBio observa directamente cómo una polimerasa copia el ADN en tiempo real dentro de un pozo nanométrico. La polimerasa recorre el mismo fragmento varias veces acumulando precisión (HiFi). Lecturas largas que resuelven regiones genómicas complejas que Illumina no puede.

Oxford Nanopore hace pasar la hebra de ADN a través de un nanoporo molécula por molécula. Cada base interrumpe la corriente eléctrica de forma distinta; el algoritmo de basecalling decodifica la secuencia en tiempo real. El MinION es del tamaño de un USB y puede usarse en campo.

> Para el prototipo GEN-MAMA-MX: TCGA-BRCA ya fue secuenciado con Illumina — el pipeline arranca directamente en el paso 4, sin necesidad de laboratorio. Para el proyecto clínico real con pacientes de IMSS/ISSSTE Hermosillo, Illumina WES a ~$300/exoma es el estándar recomendado. El INMEGEN en CDMX ofrece este servicio con equipo de última generación.

5. AlphaFold 3 y Docking Molecular: del Gen al Fármaco

5.1 ¿Por qué la estructura 3D importa?

Una mutación genética no es peligrosa por sí misma — es peligrosa porque cambia la FORMA de la proteína que produce el gen. Y la forma de una proteína determina todo: cómo interactúa con otras moléculas, si activa rutas de proliferación celular descontrolada, y sobre todo, dónde puede unirse un fármaco para bloquearla.

AlphaFold 3 de Google DeepMind puede predecir la estructura 3D de cualquier proteína a partir de su secuencia de aminoácidos, con precisión comparable a cristalografía de rayos X — un proceso que antes tomaba años y costaría millones de dólares. Hoy toma horas y es gratuito para investigación.

5.2 Comparación WT vs. Mutada

El análisis central de GEN-MAMA-MX es comparar dos estructuras para cada variante identificada:

- Estructura wild-type (WT): la proteína en su forma normal, modelada con AlphaFold Server.

- Estructura mutada: la misma proteína con el cambio de aminoácido del tumor, modelada con Boltz-1 (licencia MIT, sin límite de jobs diarios).
- RMSD (Root Mean Square Deviation): métrica que cuantifica cuánto cambió la geometría. Mayor RMSD = mayor cambio conformacional = mayor probabilidad de que el tumor haya alterado un sitio de actividad relevante.

5.3 Binding Pockets y Docking

Una vez se tienen las dos estructuras, el algoritmo fpocket identifica automáticamente las cavidades o hendiduras de la proteína mutada donde puede encajar físicamente una molécula pequeña (fármaco). Esta identificación del 'bolsillo de unión' es el puente entre la estructura y la búsqueda de fármacos.

El docking molecular (AutoDock Vina, DiffDock) prueba computacionalmente cientos de fármacos conocidos contra ese bolsillo, calculando la afinidad de unión en kcal/mol. Cuanto más negativo el número, más fuerte se une el fármaco al blanco.

5.4 Fármacos Repositionables

El hallazgo más valioso del pipeline: un fármaco que se une significativamente mejor a la proteína mutada que a la normal (Δscore ≤ −1.0 kcal/mol). Esto significa que podría ser específico para el tumor — atacaría la célula cancerigenósa más que la sana. Si ese fármaco ya está aprobado por la FDA para otro uso, el camino al ensayo clínico se acorta años.

> Resultado del prototipo con PIK3CA H1047R: Alpelisib (Δscore = −1.5 kcal/mol) y CHEMBL-3127 (Δscore = −1.2 kcal/mol) muestran mayor afinidad en la proteína mutada vs. WT. Alpelisib ya tiene aprobación FDA para esta misma mutación, lo que valida el pipeline.

6. Medicina Genómica en México: Estado Actual

6.1 ¿Es experimental o estándar clínico?

Para cáncer de mama, la medicina genómica ya NO es experimental en varios frentes. El Consenso Mexicano sobre Diagnóstico y Tratamiento del Cáncer Mamario 2025, publicado por FUCAM (Fundación de Cáncer de Mama), ya establece:

- Alpelisib (Piqray) como tratamiento indicado para tumores con mutación PIK3CA confirmada por NGS. FDA 2019. COFEPRIS aprobado.
- Capivasertib (Truqap) para alteraciones en la vía PIK3CA-AKT-PTEN (~40% de tumores de mama). FDA 2023.
- Olaparib (Lynparza) para mutaciones germinales BRCA1/2. Disponible en centros oncológicos de México.
- Trastuzumab (Herceptin) para tumores HER2+. Estándar desde 1998. En cuadro básico del IMSS.
- Pembrolizumab (Keytruda) para cáncer triple negativo PD-L1+. Primera línea de inmunoterapia.

6.2 ¿Quién hace medicina genómica oncológica en México?

Institución	Sector	Capacidad y relevancia
INCan (CDMX)	Público federal	Acaba de inaugurar la UniGPGBio — Unidad de Genotipificación con NGS en tumores sólidos. Estándar internacional de calidad. Emite reportes genómicos con impacto directo en decisiones clínicas. Referente nacional.
INMEGEN (CDMX)	Público federal	26 proyectos activos en cáncer. Nuevo secuenciador Illumina 2.5× más rápido. Único Posgrado de Alta Especialidad en Medicina de Precisión en Cáncer. Explora CAR-T en oncología. Socio natural para GEN-MAMA-MX.
FUCAM (CDMX)	Soc. civil	Autora del Consenso Mexicano 2025. Incluye alpelisib, capivasertib y terapias dirigidas por genómica. Atiende miles de pacientes/año, mayoría sin recursos. Aliada clave para el componente clínico.
Médica Sur / TecSalud	Privado	Médica Sur tiene servicio formal de medicina genómica para cáncer de mama. TecSalud/Hellion (Monterrey) forma parte del Consenso Mexicano 2025. Los centros privados más activos en terapias dirigidas.
IMSS / ISSSTE	Público nacional	Trastuzumab en cuadro básico. Para alpelisib y olaparib el acceso es irregular por UMAE y estado. Gran brecha: pueden aplicar el fármaco pero no siempre tienen el diagnóstico molecular. Eso resuelve GEN-MAMA-MX.

6.3 La Brecha Real

La brecha no está en la disponibilidad del fármaco. Está en el acceso al diagnóstico molecular que determina qué fármaco usar para cada paciente. La situación actual es la siguiente:

- Alpelisib existe y funciona para PIK3CA H1047R. Para prescribirlo, el oncológo necesita saber que la paciente TIENE esa mutación, lo que requiere un estudio de NGS.
- En México, menos del 3% de pacientes en el sector público acceden a ese estudio.
- Miles de pacientes con mutación PIK3CA reciben quimioterapia estándar cuando podrían recibir alpelisib, más efectivo y menos tóxico para ellas específicamente.
- No porque el fármaco no exista, sino porque nadie secuenció su tumor.

> GEN-MAMA-MX cierra exactamente esa brecha: un pipeline open-source que hace el diagnóstico molecular accesible para cualquier institución con acceso a secuenciación básica, conectando la mutación del tumor con el fármaco correcto.

7. El Prototipo en Google Antigravity IDE

7.1 ¿Qué demuestra el prototipo?

El prototipo de GEN-MAMA-MX demuestra end-to-end que el pipeline computacional es técnicamente válido usando exclusivamente datos públicos y herramientas open-source. No requiere laboratorio, pacientes reales ni presupuesto en esta fase.

Componente	Especificación
Dataset	TCGA-BRCA — 1,084 pacientes, mutaciones somáticas, acceso abierto en cBioPortal
Variantes analizadas	Top-10 variantes missense más frecuentes en genes PIK3CA, TP53, ERBB2, BRCA1/2, CDH1, GATA3, MAP3K1
Predicción estructural WT	AlphaFold Server (gratuito, 20 jobs/día) con caché local para evitar re-envìos
Predicción estructural Mut	Boltz-1 (MIT License, sin límite de jobs) ejecutado localmente o en Google Colab T4
Análisis de docking	AutoDock Vina 1.2 en batch paralelo + DiffDock para las 3 variantes con mayor RMSD
Base de fármacos	ChEMBL API (≥50 inhibidores/gen) + DrugBank Open (FDA-aprobados y en ensayo clínico)
Reporte final	HTML + PDF auto-generado con Jinja2 y WeasyPrint: perfil de variante, estructuras, RMSD, Top-10 fármacos, candidatos repositionables
IDE de implementación	Google Antigravity (Planning Mode, Gemini 3 Pro / Claude Sonnet 4.5)
Duración estimada	4 sprints de 1 semana = 4 semanas desde cero

7.2 Output por Variante Analizada

Al ejecutar python pipeline.py --variant PIK3CA_H1047R, el sistema produce automáticamente:

- Perfil genómico: gen afectado, tipo de mutación, frecuencia en la cohorte TCGA-BRCA, clasificación clínica (patogénica / VUS / benigna).
- Par de estructuras 3D: archivos .pdb de la proteína WT y mutada con score pLDDT de confianza.
- Análisis conformacional: RMSD global y en el sitio activo, imagen de superposición WT vs. Mutada.
- Ranking Top-10 inhibidores: score de docking (kcal/mol), nombre del fármaco, estado regulatorio (FDA / ensayo clínico / experimental).
- Fármacos repositionables: aquellos con Δscore ≤ −1.0 kcal/mol vs. WT, con referencia ChEMBL/DrugBank.
- Reporte HTML/PDF: documento completo auto-generado, listo para presentar como evidencia científica.